Sprint 03

Prompt and Artificial Intelligence

Equipe FFIVE:

- Augusto de Souza Ávila - RM: 570839
- Davi Simoncelo - RM: 571738
- João Pedro Sousa - RM: 573962
- Matheus Evangelista Silva - RM: 568593
- Murilo Lima de Carvalho - RM: 570156

1 – Resumo da evolução

Nas Sprints 1 e 2, o chatbot utilizava uma implementação manual em Python, com Hugging Face Inference API, histórico mantido em lista e respostas em texto livre. Na Sprint 03, o núcleo foi refatorado para LangChain LCEL, preservando a identidade do projeto e adicionando memória por sessão, Pydantic v2, prompt versionado, guardrails e avaliação automatizada.

- Chain LCEL com ChatPromptTemplate, ChatOllama e PydanticOutputParser.
- Memória por sessão com RunnableWithMessageHistory e ConversationTokenBufferMemory.
- Guardrails para prompt injection, acesso não autorizado, fora de escopo e segurança elétrica.

2 – Refatoração técnica

A versão manual foi mantida como baseline. A nova arquitetura foi separada em src/chain, src/schemas e src/guardrails. O system prompt passou a utilizar XML tagging para separar identidade, escopo, segurança, integridade de dados e regras de resposta.

O principal trade-off observado foi entre velocidade, custo computacional e confiabilidade. O gpt-oss:120b-cloud e o qwen3:8b atingiram 100% de saída estruturada válida, porém o GPT-OSS apresentou menor latência no eval. As APIs de memória vistas em aula geram warnings de depreciação nas versões atuais do LangChain, mas foram mantidas para aderência ao conteúdo da Sprint.

3 – Comparativo antes/depois

O mesmo conjunto de 8 testes foi usado para medir a evolução. O resultado histórico da Sprint 2 foi comparado com a execução final da Sprint 03.

Métrica	Sprints 1/2	Sprint 03
Respostas adequadas	5/8	8/8
Adequação total	62,5%	100%
Parcialmente adequadas	2/8	0/8
Inadequadas	1/8	0/8
Prompt injection	Falhou	Recusado
Structured output	Não havia Pydantic	100% válido
Latência média	Não registrada	1.433,01 ms
Tokens médios/turno	Não registrados	166

Observação: latência e tokens do legado não foram registrados na época. Como a reexecução exigiria a credencial externa da Hugging Face, os campos foram mantidos como “não disponível”, sem estimativas artificiais.

Evolução do system prompt

Versão	Mudança principal	Por quê	Ganho
Legado	Persona, escopo e formato	Padronizar as respostas	5/8 adequadas
Sprint 03	XML tagging + integridade + segurança	Reduzir alucinações e reforçar segurança	8/8 adequadas

4 – Comparação de modelos

Os modelos foram executados com os mesmos parâmetros: temperature 0,2, top_p 0,9 e num_predict 512. O gpt-oss:120b solicitado no enunciado foi usado pela variante gpt-oss:120b-cloud via Ollama Cloud, enquanto o qwen3:8b foi executado localmente via Ollama.

Métrica	gpt-oss:120b-cloud	qwen3:8b
Testes adequados	8/8	8/8
Nota do eval	100%	100%
Structured output válido	100%	100%
Latência média	1.433,01 ms	22.641,46 ms
Tokens médios/turno	166	119
temperature	0,2	0,2
top_p	0,9	0,9
num_predict	512	512

O gpt-oss:120b-cloud e o qwen3:8b atingiram 8/8 respostas adequadas e 100% de structured output válido. O GPT-OSS apresentou menor latência média e foi definido como modelo principal por atender diretamente ao modelo solicitado na arquitetura de referência. O llama3.2:3b também foi avaliado como evidência adicional e apresentou falhas de parsing em vários testes.

5 – Problemas e soluções

Python 3.14 — a stack do LangChain apresentou incompatibilidade. O ambiente foi recriado com Python 3.12.

Modelo principal — o gpt-oss:120b solicitado no enunciado foi executado pela variante gpt-oss:120b-cloud via Ollama Cloud, mantendo ChatOllama na chain.

Alucinações — o modelo chegou a inventar portas, códigos e canais de suporte. O prompt recebeu regras explícitas de integridade de dados.

Structured output — o llama3.2:3b respondeu em XML. O runner passou a registrar falhas de parser sem interromper a bateria de testes.

6 – Equipe e divisão de trabalho

Nome	RM	Tarefa principal
Augusto de Souza Ávila	570839	Testes do chatbot
Davi Simoncelo	571738	Desenvolvimento do chatbot
João Pedro Sousa	573962	Memória da conversa
Matheus Evangelista Silva	568593	Estrutura das respostas
Murilo Lima de Carvalho	570156	Segurança e documentação

Conclusão

A Sprint 03 evoluiu o ChargeGrid de uma solução manual para uma arquitetura LCEL com memória, validação Pydantic v2, guardrails e avaliação reproduzível. O ganho medido foi de 62,5% para 100% de respostas totalmente adequadas, com 100% de structured output válido no gpt-oss:120b-cloud e recusa correta ao teste de prompt injection.