Sprint 04

Prompt and Artificial Intelligence

Equipe FFIVE:

- Augusto de Souza Ávila - RM: 570839
- Davi Simoncelo - RM: 571738
- João Pedro Sousa - RM: 573962
- Matheus Evangelista Silva - RM: 568593
- Murilo Lima de Carvalho - RM: 570156

1 – Resumo da evolução

A Sprint 04 ampliou o chatbot ChargeGrid da arquitetura LCEL da Sprint 03 para uma solução RAG, capaz de consultar documentos técnicos da GoodWe e fundamentar respostas em trechos recuperados.

A base reúne quatro documentos técnicos, com 200 páginas processadas. A aplicação utiliza embeddings locais, armazenamento vetorial persistente, recuperação por similaridade e interface Gradio.

2 – Arquitetura técnica

PyMuPDFLoader → RecursiveCharacterTextSplitter → OllamaEmbeddings (nomic-embed-text) → ChromaDB → Retriever top-k → ChatOllama (qwen3:8b) → Gradio.

Foram testadas duas configurações de chunking e recuperação com o mesmo conjunto de cinco perguntas. As respostas mantêm restrições de escopo e recusas quando não há evidência suficiente.

3 – Comparativo antes/depois

A mesma bateria de cinco perguntas foi aplicada ao RAG. V1 e V2 usam busca semântica; V3 acrescenta busca direcionada para segurança e prompt em português.

Métrica	V1	V2	V3
Chunk size	512	800	800
Chunk overlap	80	120	120
Top-k	3	4	4
Chunks indexados	403	297	297
Respostas relevantes*	3/5	4/5	5/5
Sucesso funcional*	60%	80%	100%

Evolução da recuperação

A V1 confundiu os modelos HCA G2. A V2 identificou GW7K-HCA-20, GW11K-HCA-20 e GW22K-HCA-20. A V3 manteve esses acertos e recuperou instruções de segurança do manual HCA G2 (páginas 3, 9 e 10), antes ausentes nos resultados.

*Avaliação funcional preliminar: cinco perguntas, sem RAGAS oficial. O 5/5 não comprova 100% de faithfulness: uma citação à página 5 do manual HCA G2 precisa de correção ou validação. Resultados sujeitos à revisão humana.

4 – Comparação de modelos

Foram comparados Qwen3 8B e Llama 3.2 3B nas mesmas cinco perguntas do RAG V2 (10 execuções, sem erros).

Critério RAG V2	Qwen3 8B	Llama 3.2 3B
Modelos HCA G2	Correto, com fonte	Recusou
Segurança instalação	Recusou	Recusou
Consulta SEMS+	Respondeu e citou	Respondeu sem citar
Fora do escopo	Recusou	Recusou
Prompt injection	Recusou	Recusou

Seleção e parâmetros

O Qwen3 8B foi mantido como modelo principal por apresentar melhor cobertura e citações nos testes RAG. O Llama 3.2 3B foi avaliado como alternativa local. Os testes de prompt injection foram barrados pelo pipeline antes da chamada ao modelo.

Configuração RAG V2/V3: temperatura 0; top_p 0,9; máximo de 512 tokens previstos; top-k 4; embeddings nomic-embed-text; ChromaDB persistente. A V3 reutiliza a coleção V2.

Limitações da avaliação

A comparação dos modelos usa V2, não V3. A qualidade foi inspecionada manualmente; métricas de faithfulness e answer relevancy não foram medidas pelo RAGAS. As citações geradas precisam ser conferidas contra os trechos recuperados.

5 – Problemas, soluções e equipe

Problemas identificados e correções

1. Modelos HCA G2: a V1 citava modelos da geração anterior. A V2 passou a recuperar a ficha técnica correta, identificando os modelos terminados em “-20”.

2. Segurança na instalação: a V2 recuperava informações sobre senhas do SEMS+. A V3 passou a priorizar o manual GW_HCA-G2_User Manual-EN.pdf, com consulta em inglês e resposta em português.

3. Escopo e injeção: perguntas sem evidência e tentativa de revelar instruções internas foram recusadas nos testes. A filtragem atual é baseada em padrões e não elimina todos os riscos.

Equipe e divisão de trabalho

Integrante	RM	Atuação
Augusto de Souza Ávila	570839	Testes
Davi Simoncelo	571738	Desenvolvimento
João Pedro Sousa	573962	Memória
Matheus Evangelista Silva	568593	Respostas
Murilo Lima de Carvalho	570156	Segurança e documentação

Conclusão

A Sprint 04 incorporou RAG ao ChargeGrid. Na bateria preliminar, a relevância funcional evoluiu de 3/5 (V1) para 4/5 (V2) e 5/5 (V3). A V3 é a melhor configuração observada, mas exige validação da citação de qualificação profissional e testes mais amplos antes de afirmar fidelidade total.