Sprint 04

Prompt and Artificial Intelligence

Equipe FFIVE:

- Augusto de Souza Ávila - RM: 570839
- Davi Simoncelo - RM: 571738
- João Pedro Sousa - RM: 573962
- Matheus Evangelista Silva - RM: 568593
- Murilo Lima de Carvalho - RM: 570156

1 – Resumo da evolução

A Sprint 04 ampliou o chatbot ChargeGrid da arquitetura LCEL da Sprint 03 para uma solução RAG, capaz de consultar documentos técnicos da GoodWe e fundamentar respostas em trechos recuperados.

A base reúne quatro documentos técnicos, com 200 páginas processadas. A aplicação utiliza embeddings locais, armazenamento vetorial persistente, recuperação por similaridade e interface Gradio.

2 – Arquitetura técnica

PyMuPDFLoader → RecursiveCharacterTextSplitter → OllamaEmbeddings (nomic-embed-text) → ChromaDB → Retriever top-k → ChatOllama (qwen3:8b) → Gradio.

Foram testadas duas configurações de chunking e recuperação com o mesmo conjunto de cinco perguntas. As respostas mantêm restrições de escopo e recusas quando não há evidência suficiente.

3 – Comparativo antes/depois

A mesma bateria de cinco perguntas foi aplicada às versões V1 e V2 do RAG. A avaliação é manual, assistida por IA, e não corresponde a scores oficiais do RAGAS.

Métrica	V1	V2
Chunk size	512	800
Chunk overlap	80	120
Top-k	3	4
Chunks indexados	403	297
Faithfulness manual	100%	100%
Answer relevancy manual	60%	80%
Respostas relevantes	3/5	4/5

Evolução da recuperação

A V2 ganhou 20 pontos percentuais em relevância. Na pergunta sobre HCA G2, a V1 confundiu a família anterior; a V2 identificou GW7K-HCA-20, GW11K-HCA-20 e GW22K-HCA-20.

As pontuações exigem validação humana pelo grupo.

4 – Comparação de modelos

O comparativo abaixo usa o mesmo conjunto de oito testes do pipeline da Sprint 03, reexecutado na preparação da Sprint 04. Não equivale à avaliação RAG V1 × V2.

Métrica	qwen3:8b	llama3.2:3b
Testes adequados	8/8	2/8
Taxa de sucesso	100%	25%
Structured output	100%	25%
Latência média	18.638,79 ms	3.625,18 ms
Tokens por turno	125,5	164,5

O Qwen3 8B foi selecionado como modelo principal por atingir 8/8 respostas adequadas e 100% de saída estruturada válida. O Llama 3.2 3B foi mais rápido, porém apresentou falhas frequentes de parsing.

Os parâmetros de geração usados na reexecução devem ser conferidos nos arquivos de configuração e logs. Os resultados RAG foram avaliados separadamente com o Qwen3 8B.

5 – Problemas e soluções

Modelos HCA G2 — a V1 citou modelos da geração anterior. A V2 recuperou a ficha técnica correta, com modelos terminados em “-20”.

Segurança de instalação — a V1 recuperou instruções de senhas do SEMS+. A V2 recusou por falta de contexto adequado; a recuperação de conteúdo de segurança ainda precisa ser melhorada.

Escopo e prompt injection — ambas as versões recusaram perguntas fora do domínio e pedidos para revelar instruções internas.

6 – Equipe e divisão de trabalho

Nome	RM	Atuação no projeto
Augusto de Souza Ávila	570839	Testes
Davi Simoncelo	571738	Desenvolvimento
João Pedro Sousa	573962	Memória
Matheus Evangelista Silva	568593	Respostas
Murilo Lima de Carvalho	570156	Segurança e documentação

Conclusão

A Sprint 04 acrescentou RAG ao ChargeGrid. A V2 foi preferida por maior relevância manual (80% ante 60%), mantendo a necessidade de revisão humana e melhoria da recuperação de segurança.